计算机科学
Computer Science
ISSN 1002-137X,CN 50-1075/TP

《计算机科学》网络首发论文

题目： SQL-MARS：面向用户模糊需求的 Text2SQL 结构化数据推荐系统
作者： 徐嘉雯，郑云贵，周伟，徐尧强，胡卉芪，周烜
网络首发日期： 2025-11-21
引用格式： 徐嘉雯，郑云贵，周伟，徐尧强，胡卉芪，周烜．SQL-MARS：面向用户模糊需求的 Text2SQL 结构化数据推荐系统[J/OL]．计算机科学．
https://link.cnki.net/urlid/50.1075.TP.20251121.1155.006

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-11-21 13:26:25　网络首发地址：https://link.cnki.net/urlid/50.1075.TP.20251121.1155.006

SQL-MARS：面向用户模糊需求的 Text2SQL 结构化数据推荐系统

徐嘉雯[1] 郑云贵[1] 周 伟[1] 徐尧强[2] 胡卉芪[1] 周 烜[1]

1 华东师范大学数据科学与工程学院 上海 200062

2 国家电网有限公司华东分部 上海 200120

（51275903078@stu.ecnu.edu.cn）

摘　要　随着大语言模型（Large Language Model, LLM）技术的成熟，基于自然语言的数据库交互系统（如 Chat2DB、ChatExcel）已实现广泛应用。然而，现有系统普遍依赖于“精确查询”假设，难以应对现实场景中广泛存在的模糊需求，即用户需要在与系统交互的过程中明确其查询需求。为了应对这个挑战，本文提出 SQL-MARS（SQL-oriented Multi-Agent Recommender System），该系统基于“感知-行动-评估”闭环机制的多智能体协同框架，实现面向数据库模糊查询需求的动态判别与自适应处理。系统提出三层元数据架构建模用户需求以实现模糊感知。在此基础上系统实现数据导航功能，根据用户的模糊需求分粒度向用户推荐查询建议，渐进式引导用户澄清查询需求。同时，系统提出外部资料与本地数据融合机制，充分利用外部资料中有价值的信息。此外，我们还创建了 Bird-fuzzy 模糊需求数据集，系统实现了自动化评估。实验结果表明，SQL-MARS 能够识别模糊需求并有效引导用户澄清数据需求。

关键词：模糊需求；多智能体协作；元数据分层；数据导航；外部资料融合

中图分类号 TP311

SQL-MARS: Text-to-SQL Structured Data Recommendation System for Ambiguous User Requirements

XU Jiawen[1], ZHENG Yungui[1], ZHOU Wei[1], XU Yaoqiang[2], HU Huiqi[1] and ZHOU Xuan[1]

1 School of Data Science and Engineering, East China Normal University, Shanghai 200062, China

2 East China Branch of State Grid Corporation of China, Shanghai 200120, China

Abstract　With the maturity of LLM technology, natural language-based database interaction systems (e.g., Chat2DB, ChatExcel) have achieved wide application. However, existing systems generally rely on the "precise query" assumption and struggle to handle the ubiquitous ambiguous requirements in real-world scenarios, where users need to clarify their query needs during interaction with the system. To address this challenge, this paper proposes SQL-MARS (SQL-oriented Multi-Agent Recommender System), a multi-agent collaborative framework based on a "perception-action-evaluation" closed-loop mechanism for dynamic identification and adaptive processing of ambiguous database query requirements. The system introduces a three-layer metadata architecture to model user's requirements for ambiguous awareness. Based on this, it implements data navigation function, providing query recommendations at varying granularities based on users' ambiguous requirements to progressively guide them in clarifying their query needs. Additionally, the system proposes the fusion mechanism between external knowledge and local data to fully utilize valuable information from external sources. It also creates the dataset named Bird-fuzzy for ambiguous requirements and implements automated evaluation. Experimental results show that SQL-MARS can effectively identify ambiguous requirements and guide users to clarify their data needs.

Keywords　Ambiguous requirements, Multi-agent collaboration, Hierarchical metadata, Data navigation, External knowledge fusion

1 引言

随着大语言模型（LLM）技术的成熟，数据库智能交互得到了支持，Chat2DB[1]等系统已实现自然语言查询功能部署。然而，这些系统普遍建立在“精确查询”的理想化假设基础上，而现实应用场景中的用户查询往往包含模糊语义。例如，用户在一开始并不明确想要查询的数据具体如何表达；又例如，用户在表达“高分”时量化阈值缺失或未明确定义“就业率”对象范围等。在应对此类模糊查询时，由于结构化数据库存储范式与 LLM 对需求的语义解析之间存在本质性差异，无法实现精准映射，导致系统既无法准确识别查询需求中的模糊性，又缺乏有效的交互机制引导用户澄清需求。此外，在查询过程中，现有系统处理用户上传的外部资料时也未能有效将其与本地数据库融合，难以充分利用资料中蕴含的有价值信息来辅助查询。

举例而言，在医疗健康领域，模糊查询的普遍性严重制约了基于自然语言交互的诊疗决策系统的准确性和效率。以临床医生提出“找出需要重点关注的患者”这一典型需求为例，系统需要处理的模糊性至少存在两个维度：在对象范畴上，重症监护场景中可能指“生命体征不稳定的患者”，而在门诊随访中可能特指“复查结果异常的患者”；在指标定义层面，对于上述的生命体征指标，心内科可能关注心率变异性（HRV），呼吸科则可能侧重血氧饱和度。这些模糊的维度若不加以澄清会直接影响到最终查询结果与需求的一致性。同时，对于医生上传的相关资料，无法将其与当前数据库系统关联起来（比如资料中包含正常血氧饱和度等指标，而本地呼吸科数据库中也存在该指标）。为了推测医生模糊查询的意图，用户不得不通过多轮的试错式对话逐步明确需求（确认查询对象、异常指标、阈值定义等），这种交互模式不仅大幅增加时间成本，而且对非数据库专业的用户造成严重认知负荷。究其本质，现有的交互式数据查询系统存在如下缺陷：

1）缺乏需求模糊度判别机制；2）缺乏引导用户渐进式澄清的框架；3）对于与本地数据库相关的外部资料利用率低下。

为改进这些缺陷，我们需依次实现：语义建模用户需求，对齐数据库结构化数据；基于语义对齐结果感知需求模糊度；基于数据导航框架渐进式引导用户澄清数据需求。在澄清过程中，需要跨领域数据库引导，我们发现实体多义性导致的 SQL 生成幻觉现象亟需解决。简而言之，本文将面向用户模糊需求的数据库结构化数据导航总结为以下三项任务：

1）语义对齐建模：建立用户自然语言表达与数据库结构化数据的映射体系，消除语义鸿沟；

2）模糊感知与渐进式澄清：创建需求模糊度感知机制，根据需求模糊度通过动态反馈多粒度查询意见的方式与用户交互，引导其渐进式澄清需求；

3）SQL 生成抗幻觉优化：增强元数据语义，构建领域约束体系，解决实体多义性导致的 SQL 生成问题。

本文提出了 SQL-MARS 系统(SQL-oriented Multi-Agent Recommender System)，其技术路径围绕数据库模糊查询的全生命周期处理展开：

首先，针对任务 1），本系统提出了对元数据进行分层操作以对用户需求进行建模的方法。通过构建“库-表-字段”三级元数据网络，建立层级化语义映射体系，实现自然语言查询需求与数据库模式的端到端的语义对齐。

其次，针对任务 2），本系统提出了基于多智能体协同的数据导航框架。该框架基于四大智能体（Planner, Advisor, Seeker 和 Evaluator）实现了“感知-行动-评估”的闭环处理流程：感知过程，Planner 通过多粒度元数据探针实现需求模糊度的动态检测；行动过程采用条件触发机制，根据模糊感知结果自适应选择工作流，需求模糊时 Advisor 基于分层元数据实施多粒度需求推荐策略以引导用户澄清需求，而需求明确时 Seeker 负责 SQL 生成并执行查询检索；评估过程，

Evaluator 综合客观指标（交互轮数、响应延迟、上下文合理性反思评估）和主观指标（用户满意度）实现系统性能的量化评估。

此外，本文在 Advisor 智能体内部设计了基于文档解析器的异构数据融合工具，实现外部非结构化文档与本地数据库元数据的语义对齐，旨在从外部资料中提取有价值的指标，为 Advisor 查询建议生成补充知识源，提高推荐质量。

然后，针对任务 3），本系统提出了基于元数据语义增强的方法解决 SQL 生成过程中的幻觉现象。采用细粒度驱动的“语义反哺”策略，由字段信息增强表语义，再由表语义反向增强数据库语义，生成包含领域标记、场景标签和语义约束信息的增强元数据。在 SQL 生成过程中抑制因跨领域数据库实体多义性导致的语义歧义问题。

最后，在对系统评估阶段，我们发现面向模糊需求的评估基准存在明显断层，Spider、Bird[2]等主流数据集仅针对明确需求设计。因此，需要构建一个面向模糊需求的评估数据集。我们创建了 Bird-fuzzy 模糊需求数据集，用于系统自动化评估。

本文的主要研究贡献可归纳为以下五个方面：

1）基于分层元数据的查询需求澄清方法：构建“库-表-字段”三级语义映射体系，实现自然语言与数据库模式的端到端对齐。

2）基于多智能体协同的数据导航框架：设计一种基于“感知-行动-评估”闭环机制的多智能体协同框架，实现面向数据库模糊查询需求的动态判别与自适应处理。

3）融合外部资料与本地数据的数据探索问题推荐机制：设计基于文档解析器的异构数据融合方案，实现外部非结构化文档与本地数据库元数据的语义对齐，提取有价值的指标以辅助 Advisor 推荐查询建议。

4）基于元数据语义增强的 SQL 生成抗幻觉方法：提出细粒度驱动的反哺式语义增强策略，对元数据进行语义增强，构建领域感知的语义约束体系。

5）模糊需求数据集构建及自动化评估方法：构建 Bird-fuzzy 评估数据集（涉及 6 个领域），为面向模糊需求场景的系统评估提供了数据支持。同时，我们在该数据集上实现了针对模糊需求的自动化评估。

实验结果表明，SQL-MARS 有效支持用户完成从模糊需求到精确查询的渐进式导航过程，为模糊需求应用场景提供了解决方案。

2 相关工作

2.1 基于 LLM 的智能体研究

随着 LLM 的兴起，基于 LLM 的智能体潜力不断被探索。调用工具是 LLM 智能体的关键能力，它们弥合了 LLM 智能体与外部世界之间的差距。AutoGen[3]是 AI 智能体的开源框架，允许开发人员通过多个智能体构建 LLM 应用程序，智能体之间可以相互通信完成任务，同时配备了许多有用的工具以增强单个智能体的能力。MetaGPT[4]开创性地将人类工作流程建模为元编程框架，通过标准化操作程序（SOP）的提示编码实现多智能体的结构化协作。XAgent[5]是一个开源的大语言模型驱动的智能体，由 Dispatcher、Planner 和参与者组成，分别负责任务分派、计划生成和执行，在处理复杂指令方面的适应性、效率和精确性方面表现优秀。在自然语言与数据库交互任务中，MAC-SQL[6]和 CHESS[7]使用多智能体框架，其中专用智能体分别负责模式选择、分解和优化。使用多智能体可以将特定任务分配给特定的智能体处理，各智能体之间协调工作，能够提升整个系统的稳定性。本文同样采用多智能体的框架实现面向模糊需求的感知与导航功能。

为提升基于 LLM 的智能体的推理与规划能力，研究者提出了 ReAct 机制[8]，通过 LLM 根据当前观察生成思考与行动的迭代过程直至任务完成；Reflexion[9]则引入自反思机制以优化推理质量。本文系统在这些机制的基础上，采用元数据增强、基于 LLM 的自我反思评估、优秀示例库实现推理的优化。

2.2 LLM 和数据库的关系

大型语言模型(LLMs)凭借其海量预训练数据和强大的语义理解能力，正在重塑数据管理范式，推动下一代智能数据库系统的发展。当前 LLM 在数据库领域的应用已覆盖数据清洗[10]、查询优化[11]、SQL 等价性判定[12]及故障根因分析[13]等核心场景。

针对 LLM 在数据库交互中的关键挑战，现有研究提出了多种解决方案：DB-GPT 系统[11]通过提示生成优化、模型微调和领域适配设计解决了提示工程难题和物理特征（如数据分布）感知问题；基于 LLM 增强的数据分析平台 Chat2Data[1]通过提取领域数据生成语义向量嵌入，利用向量数据库实现自然语言查询的智能检索与响应。实现了低代码交互式数据分析，有效克服了领域知识缺失和交互效率瓶颈。

SQL-MARS 在现有系统基础上进行了功能拓展：其创新性的分层元数据导航机制支持从模糊需求到明确需求的渐进式澄清过程，实现了更全面的智能交互能力。

2.3 基于 LLM 的 Text-to-SQL 研究进展

大语言模型（LLM）凭借其强大的自然语言理解与生成能力，已成为 Text-to-SQL 任务的核心技术范式。现有研究主要围绕提示工程和模型微调两大方向展开系统优化，其技术演进可划分为三个关键阶段：

1）基础提示工程阶段：早期研究聚焦于提示模板的优化设计，包括零样本场景下的有效提示构造[14,15]以及少样本学习中的示例选择策略[16]。这类方法通过精心设计的指令模板（如“请将以下自然语言转换为 SQL 查询”）激活 LLM 的潜在能力，但受限于模型的固有能力天花板，在复杂查询场景下表现有限。

2）模块化协作阶段：为突破单一提示的局限性，研究者提出多模块协作策略。C3[17]开创性地将任务分解为模式链接、SQL 生成和 SQL 验证三个子模块，显著提升生成准确性。后续工作沿此方向持续改进：DIN-SQL[18]引入自修正机制处理语法错误，DEA-SQL[19]通过自主学习模块实现动态优化。这一阶段同时关注模式信息的有效利用，如 ReFoRCE[20]采用表压缩技术解决长上下文问题，MAC-SQL[6]则通过隐式模式分解提供程序性知识指导。

3）推理增强阶段：随着思维链（CoT）技术的兴起，研究者将其适配至 SQL 生成场景，但标准 CoT 提示效果有限。QDecomp[21]创新性地按执行流将 SQL 子句重组为逻辑步骤，相比通用 CoT 减少了错误传播。CHASE-SQL[7]进一步提出“分治”策略，通过多路径推理生成候选 SQL 并择优执行，效果得到了提升。

本系统在引导用户澄清数据需求后，需要借助 Text-to-SQL 技术将自然语言需求转化为数据库可执行的 SQL 标准化语言并执行。过程中我们将增强的元数据纳入提示词，设计具有领域约束的提示词，提升 SQL 生成质量。

2.4 对话式数据探索与自动化推荐问题生成

Maria 等人[22]关注多维度数据集的对话数据探索，提出了一种多维数据模型，将数据组织成立方体，包括维度，度量值，筛选器，通过交互确定三个维度的数据子集，并基于数据库模式描述生成自然语言建议，降低用户认知负荷。但是其对于用户查询使用正则表达式提取实体，元数据匹配采用精确键值匹配，容易丢失用户语义，泛化能力不足。

Ritwik 等人[23]聚焦于表格数据的自动化问题生成，在对话式环境中自动基于数据集的相关切片推荐有趣问题，并评估数据集切片的兴趣度得分来推荐高分问题。但是子数据集的相关切片计算复杂度高，仅适用于少量数据集的开放式数据探索，并且问题生成采用的槽填充技术局限性大，难以广泛的在真实工业场景的复杂需求中应用。

QUIS[24]关注于自动化数据探索（ADE）与洞察生成，能自动生成特定数据集的问题并给出数据洞察的可视化结果。该系统迭代式的问题生成策略不依赖于初始 fewshot 示例，能够从数据中挖掘更广泛的洞察范围，但是迭代计算时间长，不适用于用户有原始需求

和外部资料时快速数据分析的场景。

上述研究均致力于结构化数据集的开放性探索与分析[22-24]。相较于本文提出的 SQL-MARS，CLARE[22]严重依赖正则表达式和精确键值匹配，在处理自然语言表达的模糊需求时泛化能力不足，且无法利用外部资料；QUIS[24]侧重于无目标的数据探索和洞察发现，其迭代式生成策略计算成本高，且不适用于用户已有初始模糊意图并希望快速得到结果的场景。

3 面向数据库模糊查询需求的多智能体协同数据导航框架

针对数据库模糊查询需求感知与渐进式澄清问题，本研究提出如图 1 所示的“感知-行动-评估”闭环的多智能体协同的数据导航框架。该框架由四个核心智能体(Planner、Advisor、Seeker 、Evaluator)构成，通过协同工作实现需求模糊度的动态判别与自适应处理。图 1 展示了本系统的双通道处理机制（建议反馈通道/数据检索通道）以及智能体间的交互逻辑。该框架的有效运作，依赖于后续章节将详细阐述的三项核心技术支持：基于分层元数据的查询需求澄清方法（第 4 章，主要支持 Planner 和 Advisor）、基于元数据语义增强的 SQL 生成抗幻觉方法（第 5 章，主要支持 Seeker）、以及融合外部资料与本地数据的问题推荐机制（第 6 章，主要支持 Advisor）。下面 3.1 节将首先介绍各智能体功能及其协同交互机制。

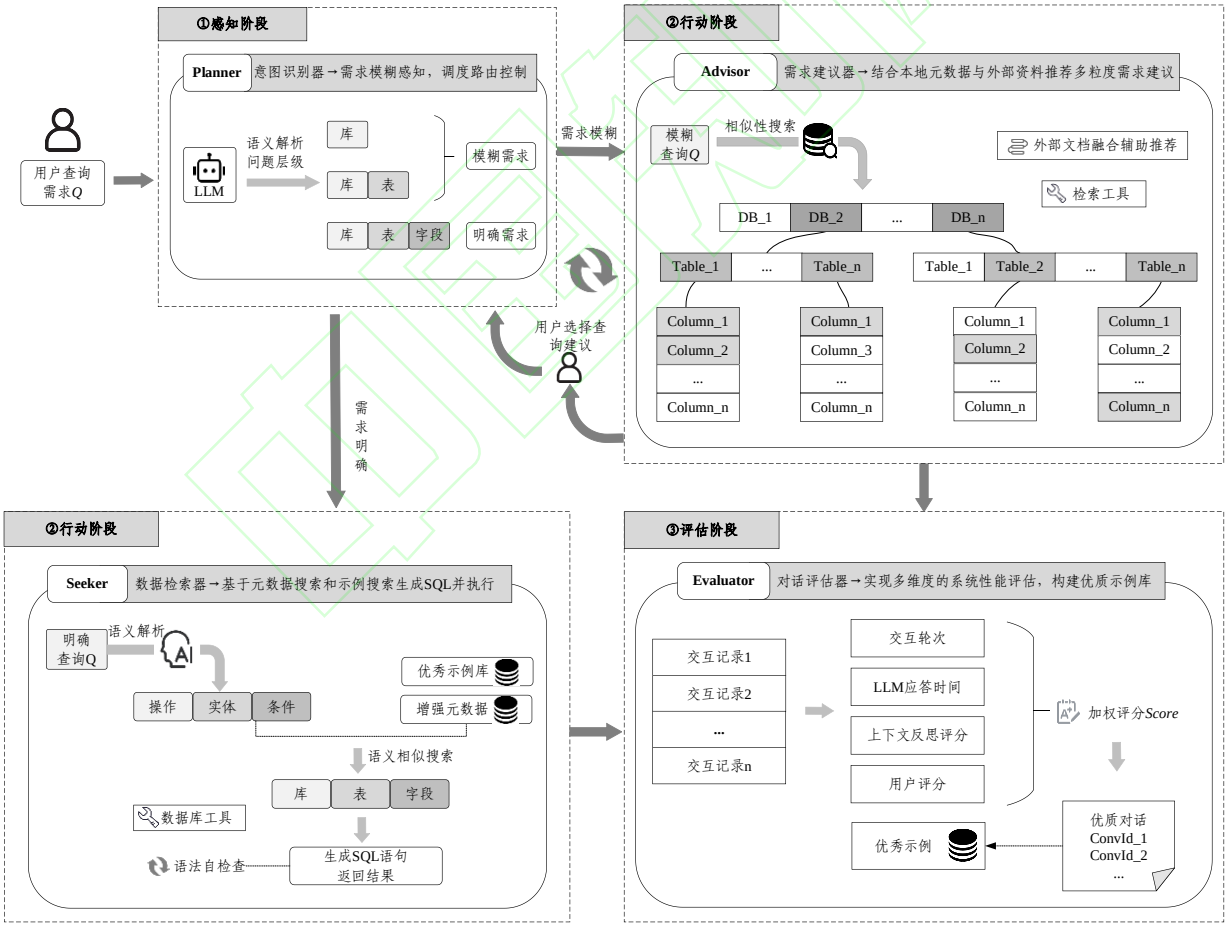

图 1 多智能体框架

Fig．1 Framework of multi-agent

3.1 框架设计

如图 1 所示，对于用户的数据库查询需求，多智能体框架的运行流程如下：首先进入①感知阶段，Planner 将给出查询需求模糊度的判定结果。然后进入②行动阶段，该阶段根据 Planner 的判定结果选择处理通道，若判定为模糊需求则路由至建议反馈通道，交由 Advisor 处理，Advisor 将采用三级渐进式查询建议推荐策略，通过多轮交互帮助用户实现需求精准化，对于每一轮用户修改的需求都需要返回 Planner 再次判定需求是否明确；若判定为明确需求，则路由至数据检索通道，交由 Seeker 处理，Seeker 将根据需求生成 SQL 并查询出最终结果。最后进入③评估阶段，Evaluator 将根据整个交互过程的信息对系统性能进行评分。下面 3.1.1 至 3.1.4 小节将详细介绍这四大智能体的功能以及实现细节。

3.1.1 Planner（感知阶段）

Planner 作为多智能体框架的核心调度枢纽，负责模糊度判定。其输入为用户的自然语言查询 Q，采用分层元数据识别机制（详见第 4 章）进行模糊度感知。它通过 LLM 对 Q 进行语义解析，将其映射到数据库的三级元数据（库、表或字段）。除了检查是否包含完整的“库-表-字段”路径外，Planner 还引入了基于语义相似度得分的阈值判定机制：若某一级（如表级或字段级）存在多个高相似度候选（相似度>0.8），则即使路径完整也判定为模糊需求，需进一步澄清。此外，Planner 还会统计歧义实体的数量，若某一层及候选数超过预设阈值（设为 3），则同样判定为模糊需求。判定结果将直接决定系统进入建议反馈通道或数据检索通道。因此，Planner 通过模糊感知实现了处理路径的动态调度，保证整个多智能体框架的自适应性。

3.1.2 Advisor（行动阶段-建议反馈通道）

Advisor 专用于处理模糊需求，通过多粒度元数据检索与分层查询建议推荐引导用户逐步明确查询意图。它接收来自 Planner 的模糊查询 Q，并启动分层引导流程。其内部集成了向量检索模块，在库、表、字段三个粒度上进行语义相似性搜索，获取 top-k 个高匹配度元数据项。同时，Advisor 配备了一个外部文档融合工具（详见第 6 章），当用户上传外部资料时，该工具会启动文档解析与指标抽取流程，从文档中识别出关键统计指标及其业务描述。这些提取出的指标信息将与元数据检索结果一同作为上下文提供给 LLM，增强其对用户潜在查询意图的理解，从而使得生成的推荐意见更贴合用户的业务场景。

整个推荐过程采用三级渐进式策略逐步实现需求精准化：首先在库级层面识别潜在数据域（如将模糊查询“学生数据”映射至教育库）帮助用户锁定查询领域；随后根据用户选择在表级推荐相关实体（如学籍表或成绩表）帮助用户锁定查询对象；最后在字段级明确具体分析维度（如 GPA 或就业率）帮助用户锁定查询指标。其中每一层的候选推荐均需满足跨层级一致性校验（如仅保留“教育库→学籍表→GPA”的完整路径），并充分融合从外部文档中提取的指标线索，结合 LLM 生成满足当前场景的自然语言建议（如“您是否需要查询数据学院本科生的就业率？”），生成三级建议的 prompt 详见 github 项目仓[1]。用户选择推荐的某个建议之后再次送至 Planner 进行新一轮模糊度感知，如此循环往复，通过多轮交互逐步收敛至明确需求。

3.1.3 Seeker（行动阶段-数据检索通道）

Seeker 专用于处理明确需求，实施增强型检索 SQL 生成流程。其输入为用户已明确的自然语言需求 Q。Seeker 首先对 Q 进行语义解构，识别其操作类型、目标实体及约束条件。随后，它在语义增强的元数据向量库（详见第 5 章）和优质查询示例库（RAG 架构）中联合检索，检索结果与用户查询 Q 共同构成提示词，确保生成的 SQL 语句既符合语义意图又适配实际数据库。生成的 SQL 会调用语法自检查工具进行规范性验

[1] *https://github.com/XuJiawen2001/SQL-MARS.git*

证。最终通过查询执行工具获取结果并反馈给用户。

3.1.4 Evaluator（评估阶段）

Evaluator 实现了多维度的系统性能评估。Evaluator 会记录下交互过程中的会话交互轮次、LLM 响应时间两个客观指标，并结合 LLM 对上下文合理性的自动评分（语义连贯性、需求满足度等）及用户显式反馈（评分）两个主观指标，通过加权计算获得综合评分。评分高于阈值（80 分）的对话会被向量化后存入知识库中，形成关键知识沉淀：一方面作为建议反馈通道的优质示例库，通过相似性检索提升后续意图预测的准确度；另一方面作为数据检索通道的语法模式库，减少明确需求下的 SQL 生成错误。这一阶段不仅实现了系统表现的量化评估，更通过持续的知识沉淀形成整个导航框架的自我优化能力。

3.2 关键技术挑战

整个多智能体协同数据导航框架在实现过程中面临以下三个核心挑战，这些挑战直接影响模糊查询需求场景下引导的有效性(能够渐进引导用户澄清需求)与生成 SQL 的可靠性（生成的 SQL 在数据库中可执行）：

1）自然语言模糊需求与数据库结构化数据映射问题

用户的模糊需求是以自然语言形式表达的，而数据库中存储的是结构化数据，两者之间存在语义鸿沟，无法进行有效映射，所以无法进一步通过判断需求的元数据路径完整性来实现模糊度感知与渐进式引导。

2）语义歧义导致 SQL 生成的幻觉问题

在跨领域数据中，即使用户明确自己的数据需求，由于相同实体在不同业务场景下存在多义性冲突（如“表现”在教育领域指“成绩”，在人力资源领域对应“业绩”），基于向量相似度的元数据检索面临语义歧义问题，无法准确定位到数据库中的目标“库-表-字段”序列，导致生成看似语法正确但语义失准的无效 SQL。

3）外部资料与本地元数据的融合问题

用户上传的外部文档（如分析报告）中使用的业务术语与本地数据库元数据之间往往存在三重差异：

A.主体差异：外部资料描述的实体（如“软件学院研究生”）在本地数据库（仅有“数据学院本科生”）中无直接对应；

B.术语差异：外部资料使用业务术语，而数据库多采用英文编码字段。

C.粒度差异：外部指标通常为复合计算（如“就业率”），而数据库仅存储基础字段。

上述挑战直接影响多智能体系统的实用性与可靠性。本文后续章节将分别针对这些挑战提出解决方案，并与框架中的智能体功能紧密对应：

针对挑战 1，第 4 章提出分层元数据架构。将为 Planner 的模糊度判定和 Advisor 的分层推荐提供基础的语义映射支持，是实现渐进式引导的前提。

针对挑战 2，第 5 章提出元数据语义增强方法。将直接应用于 Seeker 的检索与 SQL 生成流程，通过引入领域约束抑制幻觉，确保生成 SQL 的语义准确性。

针对挑战 3，第 6 章提出外部文档解析与融合机制。将作为 Advisor 的辅助工具，为其提供额外的意图线索，增强推荐建议的精准性和上下文相关性。

4 基于分层元数据的查询需求澄清方法

如第 3.2 节所述，自然语言查询需求与结构化数据之间存在语义鸿沟（挑战 1），这是实现模糊感知与渐进式引导的首要障碍。本章旨在应对这一挑战，为第 3 章中所述 Planner 的模糊判定功能以及 Advisor 的分层查询建议推荐功能提供核心技术支撑。

该挑战的根源在于两者在数据组织方式和表达形式上存在异构性。数据库中的结构化数据可以天然地抽象出“库-表-字段”三个粒度级别。通过检测需求的语义解析结果能否映射出完整的“库-表-字段”访问路径，我们可以有效评估查询需求模糊度，并据此逐步引导用户澄清其数据需求。基于这一思路，本章提出了一种基于三级元数据抽象的模糊需求建模与渐进式澄清方法。下文将详细介绍分层元数据架构的具体实现。

4.1 分层元数据抽象架构

分层元数据的目标是将数据库元数据抽象为三个层级结构：

1）库级（Database Level）：标识完整的数据库实例，包括数据库名称、包含的表列表等全局信息。

2）表级（Table Level）：描述数据库中的各个数据表，包括表名、表包含的所有字段等信息。

3）字段级（Column Level）：定义表中各个字段的详细信息，包括字段名、数据类型、字段示例（每个字段取出数据库中的 3 个真实值）等信息。

4.2 分层元数据抽象方法

如图 2 所示，系统以多源 SQLite 数据库文件作为原始数据输入，使用 Python-sqlite3 接口自动化解析 Schema。具体而言，首先提取所有数据库实例，继而依次解构每个数据库中的表结构及字段属性。最终构建具有严格层级关联的“库-表-字段”元数据网络。

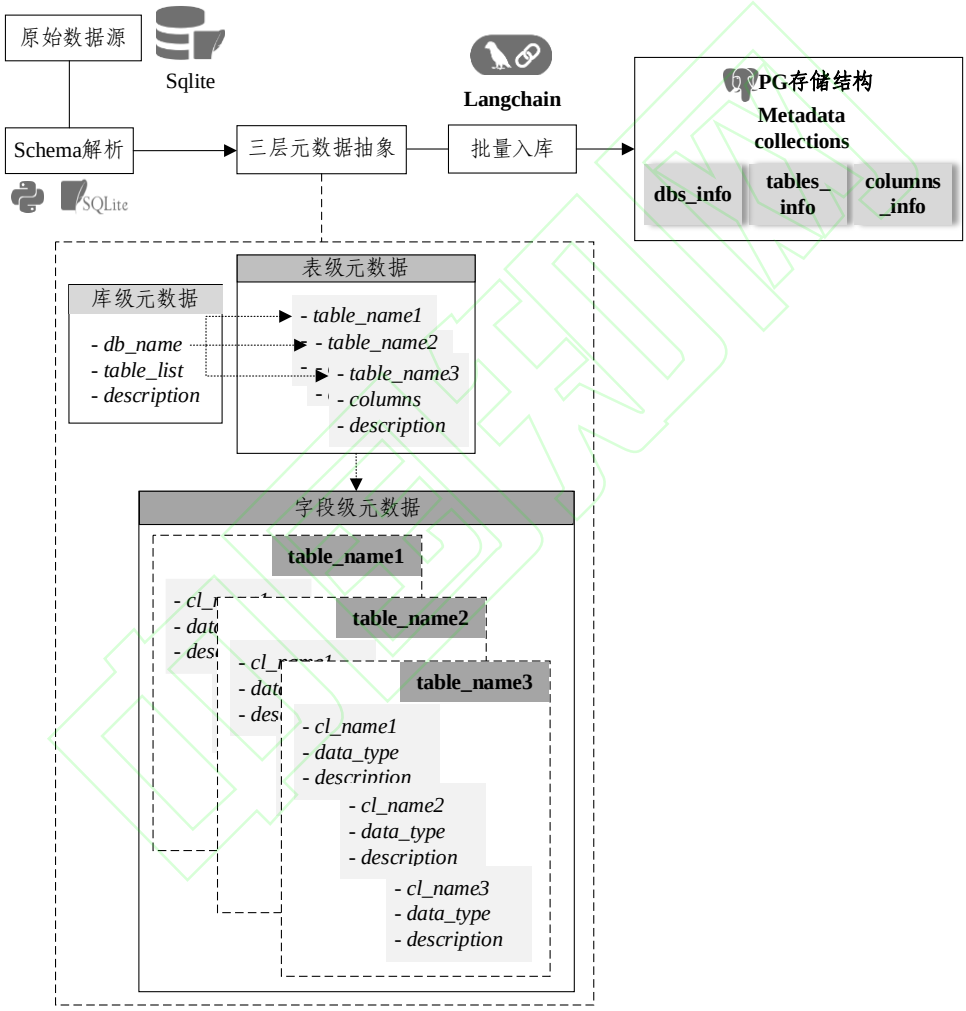

图 2 元数据分层架构

Fig. 2 Architecture of hierarchical metadata

4.3 分层元数据表征方法

基于上述抽象出的三层元数据，为提高语义表征能力，本文按照“自上而下”的流程构建粗粒度到细粒度的统一的语义表示体系。

首先表征库级元数据（包括库名、库包含的表）。采用 Qwen2.5-Coder-32B 模型为其生成自然语言描述（如"california_schools"数据库的描述为“该数据库包含加州公立学校的 FRPM（免费和减价午餐）统计数据、

SAT 成绩以及学校基本信息，可用于教育公平分析。”），数据库描述生成的 prompt 详见 github 项目仓。而后将数据库描述作为上下文信息借助 LLM 对该数据库进行领域识别（分为 EDU, FIN, MED, SPO, TECH, ENT6 大领域），生成领域标签。

然后表征表级元数据（包括表名、表包含的字段）。同样为其生成自然语言描述（如"satscores"表的描述为“该表记录了加利福尼亚州各学校的 SAT 成绩相关信息，包括学校代码、学校类型、学校名称、学区名称、郡名称、2012 年在校学生人数、参加测试的学生人数、平均阅读分数、平均数学分数、平均写作分数以及获得 1500 分及以上的学生人数，用于教育统计数据和分析。”），数据表描述生成的提示词详见 github 项目仓。而后将该描述作为上下文，在所属库的领域标签约束下推测表的核心功能和潜在用途（表 1 以 California Schools 数据库的 schools 表为例）。

最后表征字段级元数据（包括字段名、数据类型、字段示例）。同上，生成自然语言描述（如"CDSCode"字段的描述为“学校的唯一标识码。14 位代码，由 County+District+School 组成”），获取字段属性值的特征，字段描述生成的提示词详见 github 项目仓。而后将获得的信息作为 LLM 上下文，在所属库-表的领域约束下，进行字段备选描述生成、类别判断（区分度量字段与维度字段，维度字段往往可用于统计指标计算）、关联分析（表 2 以 California Schools 数据库的 schools 表的"School"字段为例）。

最终对于表征好的三级元数据，通过 BGE-M3-Latest 嵌入模型编码为 1024 维向量，经 LangChain 框架标准化封装后，按粒度分层存储至 PostgreSQL 向量数据库的三个集合中 dbs_info（库级）、tables_info（表级）和 columns_info（字段级）。

表 1 表级元数据表征示例（California Schools-schools）

Table 1 Example of table-level metadata representation（California Schools-schools）

字段	含义	分析结果
domain	所属领域	EDU
core_function	核心功能	"存储加州学校的基础信息，包括地理位置、学校类型和基础设施等核心属性"
key_entities	关键字段	["school_id", "district_code", "school_type"]
potential_use_cases	潜在用途	["学校资源公平性分析", "特许学校与传统学校对比"]

表 2 字段级元数据表征示例（California Schools_schools_school）

Table 2 Example of column-level metadata representation(California Schools_schools_school)

字段	含义	分析结果
domain	所属领域	EDU
fields_type	字段类型（维度/度量）	dimension
relations	关联分析	{"table": "satscores", "field": "sname", "scenario": "查询学校 SAT 成绩"}
field_aliases	备选描述	["公立学校", "FPC (FAME Public Charter)", "学府"]

4.4 渐进式澄清方法

基于三层元数据可以通过结构化匹配解决模糊需求的判别问题。对于模糊需求的澄清问题，我们可以对表征好的分层元数据进行语义相似性搜索来解决。当用户提交查询需求时，系统将其语义解析，判断是否已明确“库-表-字段”完整路径；若未明确则通过向量相似度计算（similarity_search）搜索各层级 top-k 个高

匹配度元数据，基于搜索到的元数据以及上下文信息组织多粒度需求建议，在三个层级分别推荐。用户可通过选择最匹配的推荐项逐步明确查询意图，完成需求澄清。

5 基于元数据语义增强的 SQL 生成抗幻觉优化法

如第 3.2 节所述，语义歧义问题（挑战 2）易导致 SQL 生成过程中出现幻觉现象，严重影响 Seeker 在数据检索通道中的输出可靠性。本章旨在应对这一挑战，通过为元数据注入丰富的语义信息，提升 Seeker 生成 SQL 的语义准确性，从而有效缓解跨领域查询中的多义性冲突问题。

在跨领域数据库的自然语言查询场景中，即使用户明确表达了数据需求，仍然可能因为实体多义性导致语义歧义问题。以“表现”一词为例，在教育领域常被解释为学生的成绩，而在人力资源管理场景中通常指员工的绩效指标。传统向量匹配方法由于缺乏深度的上下文建模能力，难以准确识别领域特定的语义指向，导致生成的 SQL 查询虽然语法正确但语义失准，严重影响了查询结果的业务相关性。

为了解决上述问题，本章节提出一种基于元数据语义增强的歧义消除方法。整体结构如图 3 所示，一方面，将“自上而下”的分层元数据表征信息纳入提示词，使 LLM 能够更好地理解语义；另一方面，实施反哺式语义增强，通过“自底向上”的信息传递路径，在第 4 章获得字段级精细语义后，由字段级信息增强表级语义，再由表级语义反向增强数据库级语义：

1）字段信息增强表信息：通过字段之间的上下文联动与语义归一，提升表的语义清晰度与一致性。结合字段表征时生成的字段描述、关联分析结果、备选描述、字段类型，重构表的描述、语义场景等以达到增强表信息的目的。

2）表信息增强库信息：基于表间语义聚合，推断数据库的核心业务语义，基于此修改数据库的描述，完成增强数据库信息构建。

最终生成的增强元数据包含领域标记、场景标签和语义约束三重信息，提升了数据库语义空间的一致性与判别能力，为查询推荐提供了场景指向，为后续的自然语言到 SQL 映射提供了更高质量的语义基础，有效抑制因语义歧义导致的查询幻觉现象。

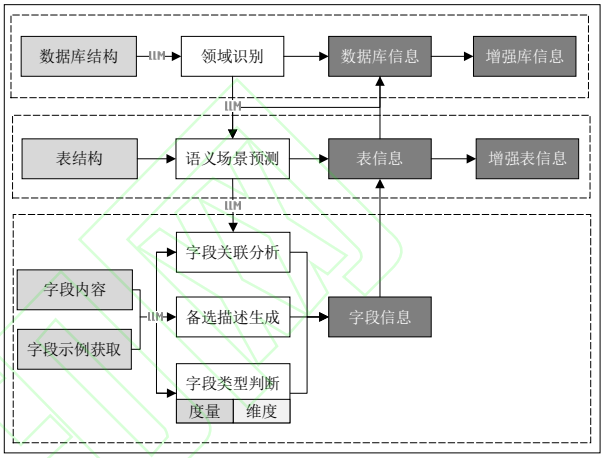

图 3 元数据增强过程

Fig. 3 Workflow of metadata-augmented

6 融合外部资料与本地数据的数据探索问题推荐机制

如第 3.2 章所述，外部资料与本地元数据在主题、术语和粒度上均存在差异（挑战 3），为查询意图的捕捉带来了额外困难。本章旨在应对该挑战，通过构建一个融合外部资料与本地元数据的语义桥梁，扩展 Advisor 的上下文感知与推荐能力。它作为 Advisor 的一个辅助工具被调用，能够在用户上传外部文档后自动解析文本、提取关键统计指标，并生成与本地数据库语义一致的高质量查询建议，从而更高效地引导用户澄清模糊的数据需求。

在真实的数据探索场景中，用户提供的报告、文档等外部资料往往蕴含重要的查询意图线索。例如，若用户上传一份《软件学院招生数据分析报告》，即使本地数据库中仅存有“数据学院就业数据”，系统仍可借助外部语义推断并推荐如“统计数据学院招生情况”

等潜在查询方向。这种跨源语义融合能力显著提升了模糊需求的识别与澄清效率。

本章提出的融合外部资料与本地数据的数据探索问题推荐机制通过构建完整的处理链路（外部资料解析与统计指标实体抽取→元数据验证与指标选择→智能问题生成与推荐）实现该功能。我们充分认识到，从非结构化文本中自动化、高精度地抽取指标公式涉及到对自然语言的深层理解和数学逻辑解析，本系统未追求完全通用的公式抽取，而是采用宽松抽取与严格验证相结合的方式提高最终推荐问题的质量。下文将详细介绍该融合机制的实现流程。

6.1 外部资料解析与指标实体识别

基于 LangChain 的文档处理流水线，采用中/英文友好的文档分块方式将外部资料（PDF 格式）切分为语义连续的文档块。随后，指标抽取器会识别文本中的统计指标（如“就业率”、“毕业生薪资”，“毕业生总人数”），对于一些需要聚合等操作的统计指标（如“就业率=就业人数/毕业生总人数×100%”），解析出相应的数学计算公式，并且对于公式中涉及的每个字段生成业务场景下的语义描述。

指标抽取器通过文本块，以及优质示例库中的数据指标抽取实例填充到统计指标抽取的提示词模板中（具体的 prompt 详见 github 项目仓库），使用 LLM 抽取文档块中的统计指标实体。其中最核心的是对于指标计算公式的解析，提示词的系统指令要求 LLM 使用“SQL 语法结构”，并且将公式中涉及的过滤条件放入 where 子句中。对于最值、均值、计数、求和字段使用聚合函数实现，避免 LLM 使用预设字段导致幻觉，旨在提升指标公式抽取的准确性。指标抽取器调用 LLM 进行指标抽取后，将返回结果解析为指标抽取列表存入本地缓存，用于后续元数据匹配和问题推荐，同时避免重复文本块对 LLM 的多次调用。

通过指标抽取模板设计提高文本块指标抽取的召回率，充分挖掘外部资料包含的指标，并由后续的“元数据验证与指标选择”环节充当严格的过滤器，实现“宽松抽取”与“严格验证”相结合的模式提升最终推荐问题的质量。

6.2 元数据验证与指标选择

在语义对齐阶段，如图 4 所示，使用 BGE-M3 嵌入模型将外部资料中抽取到的指标对应的描述与本地数据库的列级元数据同时映射到统一的语义空间，计算两者的向量相似度；然后设置动态匹配阈值进行指标选择。考虑到统计指标的复杂性，一个有意义的统计指标可能是对数据库中某个数据子集基于列值或者时间序列的综合分析，因此将指标计算需要的字段与列级元数据匹配的结果会出现多种情形（如“部分匹配”、“完全匹配”），本方法中仅当指标公式中所有字段都满足阈值要求时，即“完全匹配”时判定该统计指标可以在本地数据库查询并选中该指标，反之丢弃该指标。此外，需要注意的是，匹配阈值可以根据不同应用场景进行调整，对于金融，医疗等精细化要求高的领域可以设定为 0.9 及以上。

6.3 智能问题生成与推荐

对于通过验证的统计指标，整合匹配字段的元数据信息（元数据描述等）和原始文本块（含上下文业务信息），将其作为输入提供给 LLM，生成符合领域场景的数据分析问题，作为查询意图参考传递给 Advisor 智能体，辅助其生成符合用户认知习惯的自然语言查询建议。

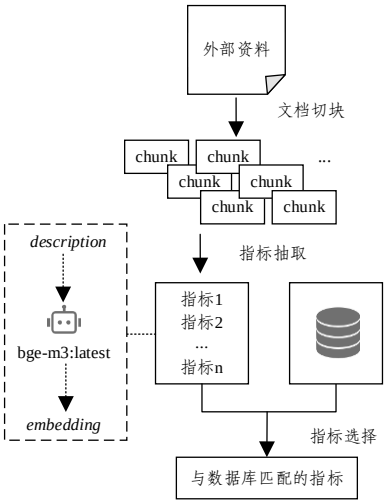

图 4 外部资料与本地元数据融合流程

Fig. 4 Fusion process of external knowledge and local metadata

7 案例分析

本章节通过具体案例，将本文提出的 SQL-MARS 系统与基线方法（Baseline）进行对比分析，以凸显 SQL-MARS 在处理模糊查询需求时的有效性与优势。

7.1 基线方法介绍

我们选择的基线采用零样本、单轮的查询方式。将用户的自然语言查询与未经分层化处理的混合的数据库元数据（即所有数据库的 schema 拼接成一个长文本）一次性输入到大语言模型中，直接利用 LLM 的理解和生成能力将自然语言转换为SQL查询语句，不含交互澄清机制。为实现公平对比，我们使用与 SQL-MARS 系统相同的 LLM 作为基线方法的推理引擎。我们选择此方法作为 Baseline，旨在清晰地揭示：若缺乏针对模糊查询的专门设计，现有系统将面临的根本性困境。

7.2 教育领域场景对比分析

1）SQL-MARS

交互过程如表 3 所示。

第一轮，用户给出的查询“学生信息”判定为模糊查询。由于数据集跨六大领域，有多个领域涉及“学生信息”，所以系统会搜索分层元数据库，分别从库、表、字段级猜测用户查询意图。库级层面聚焦“学生社团成员信息”、“加利福尼亚学生信息”、“学生银行账户及贷款信息”，分别对应数据集中的 student_club，california_schools，financial 数据库，横跨 EDU 和 FIN 两大领域。相应的，表级层面关联到具体的表格给出具体事件的查询推荐，字段级层面给出具体属性的查询推荐。

第二轮，用户选择库级推荐建议“加利福尼亚州学生信息”。系统会识别到库级需求已明确，则反馈的表级、字段级查询建议会限定至 california_schools 库以提升推荐质量。

第三轮，用户没有选择建议，而是上传文档。如图 5 所示，系统首先会执行提取文档指标（“SAT 优秀率”等）、映射本地数据库字段（如 NumGE1500→SAT 高分人数）两大步骤。然后判断指标与当前上下文用户的模糊需求（“加利福尼亚学生信息”）相符，进而生成对应的字段级查询建议。

用户最终选择查询“哪些学校的学生 SAT 优秀率超过 90%”，此时系统判定需求明确，生成对应的 SQL 以及解释，并将查询结果反馈给用户。该 SQL 与用户的真实意图相符且可执行。

2）Baseline

最终生成的 SQL 既不满足用户查询意图，也无法执行出结果。由生成的 SQL，我们可以发现查询的是 student_club 库的事件信息，与用户的意图（“学生信息”）不符。

此案例典型地揭示了基线方法在模糊查询场景下的固有缺陷。一方面，大语言模型从模糊需求中获得的信息有限，由于 student_club 和 california_schools 数据库都涉及到“学生信息”，导致使用另一数据库领域的元数据回答问题，出现答非所问现象。另一方面，由于查询的时候没有提供增强的元数据（特别是字段示例值），LLM 过度依赖语义联想，此处表现为 "status = 'active'"，数据库中的 status 字段只存在 Open，Closed，Planning 三个可能属性值。

7.3 金融领域场景

1）SQL-MARS

交互过程如表 4 所示。

第一轮，用户给出的查询“查询用户消费情况”判定为模糊查询。由于“消费”一词在不同领域表述不同，所以系统会将涉及到该关键词的领域都推荐给用户，方便用户首先锁定自己的查询领域。库级层面聚焦“信用卡交易消费”、“客户订单消费”、“学生社团财务”，分别对应数据集中的 debit_card_specializing，financial，student_club 数据库，横跨 EDU 和 FIN 两大领域。表级层面、字段级层面给出的推荐与上述的领域保持一致。

第二轮，用户选择库级推荐建议“客户的消费记录”。系统会识别到库级需求已明确，则反馈的表级、字段级查询建议会限定到 debit_card_specializing 数据库以提升推荐质量。为帮助用户建立对数据库的初步认知，系统会在建议中附带相关的元数据信息。

第三轮，用户选择建议“查询 yearmonth 表中特定客户的每月消费详情”。可见用户需求已明确至具体数据表，因此系统将聚焦于该表的字段属性值与聚合指标，并据此提供查询建议。

第四轮，用户选择查询“找出 2013 年消费最多的客户”，系统识别查询需求已明确，系统生成 SQL 并将查询结果返回给用户。至此，交互结束，整个过程中，

系统在逐级引导用户明确需求，遵循“锁定领域—锁定事件—锁定指标”的渐进式澄清链路，保证最终生成高质量的 SQL。

2）Baseline

此场景下生成的 SQL 可执行但与用户意图不符。同样存在与教育场景相似的问题，这是因为 financial 和 debit_card_specializing 数据库属于同一领域，都涉及到“消费”的信息，而大语言模型从模糊需求中获得的信息有限，且无法通过与用户交互对同一领域内的相似子库进行选择。进一步验证了基线方法的局限性：不具备与用户交互的能力，完全依赖 LLM 自身的能力从模糊需求中猜测用户意图。

7.4 小结

综上，由上述两个场景案例可见，Baseline 存在以下两个共性问题：

1）多领域歧义问题：模糊查询中的关键词在不同领域中表述不同，往往涉及多个数据库，因模糊需求中的信息有限且无法与用户交互，出现答非所问现象。

2）元数据幻觉问题：LLM 因缺乏字段级示例等增强数据，导致过度依赖语义联想，生成的 SQL 存在幻觉现象。

相比之下，本研究提出的 SQL-MARS 方法可以先推荐粗粒度的需求帮助用户锁定领域，然后再渐进式推荐细粒度的查询建议，逐渐帮助用户锁定查询对象、查询指标，可以有效避免上述基线方法存在的问题。可见 SQL-MARS 在模糊需求场景下的有效性，以及面向模糊需求的数据导航的必要性。

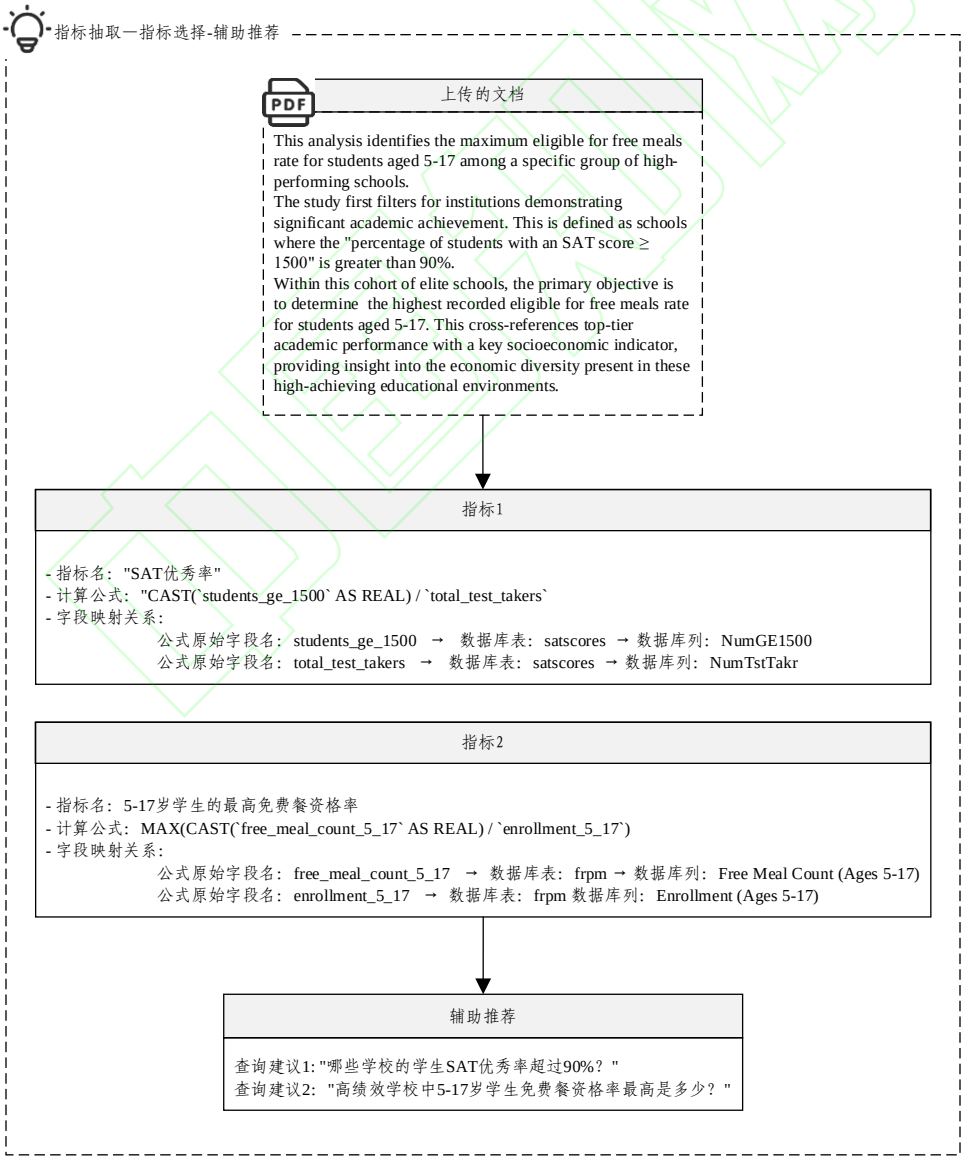

图 5 外部资料融合案例（教育场景）

Fig. 5 Case study of external knowledge integration (education scenario)

表 3 教育领域场景案例对比

Table 3 Comparison of case studies in educational domain

轮次	用户操作	系统反馈		
SQL-MARS				
1	“查询学生信息”	库级建议： - 查询学生社团成员信息 - 查询加利福尼亚州学生的信息 - 学生银行账户信息及贷款详情	表级建议： - 查询学生的基本个人信息，包括姓名、联系方式等 - 查询学生的专业、院系信息 - 查询各社团活动学生参与信息	字段级建议： - 查询所有学生的联系电话和电子邮件地址 - 查询特定学生的成绩表现 - 查询学生在社团中的具体职位
2	“查询加利福尼亚州学生信息”	表级建议： - 查询加利福尼亚州各学区的贫困学生比例 - 查询加州各学校的学生 SAT 成绩分布情况 - 查询加利福尼亚各学校的地理位置及联系方式	字段级建议： - 统计加州各学校的在校 5-17 岁学生人数 - 加州各学区享受免费午餐学生的数量占比 - 统计加州各高中参加 SAT 并取得高分的学生人数	
3	上传文档	指标抽取："SAT 优秀率"，"5-17 岁学生的最高免费餐资格率" 字段级建议： - 您是否对学校学生的 SAT 成绩感兴趣？例如：“哪些学校的学生 SAT 优秀率超过 90%？” - 您是否对学校学生 SAT 的平均分数感兴趣？例如：“加州各学校的 SAT 写作考试平均成绩” - 您是否对学校学生 SAT 的平均分数感兴趣？例如：“加州各学校的 SAT 写作考试平均成绩” - 您是否关注学校学生的福利状况，例如：“高绩效学校中 5-17 岁学生免费餐资格率最高是多少？”		
4	“查询哪些学校的学生 SAT 优秀率超过 90%”	生成 SQL： SELECT sname, (NumGE1500 / NumTstTakr) * 100 AS SAT_Excellent_Rate FROM satscores WHERE (NumGE1500 / NumTstTakr) * 100 > 90;		
Baseline				
1	“查询学生信息”	生成 SQL： SELECT event_name, event_date, location FROM event WHERE status = 'active'		

表 4 金融领域场景案例对比

Table 4 Comparison of case studies in financial domain

轮次	用户操作	系统反馈		
SQL-MARS				
1	“查询用户消费情况”	库级建议： - 查询信用卡交易中的消费情况 - 查询金融数据库中的客户订单信息 - 查询学生社团的财务支出与收入情况	表级建议： - 查询客户的信用卡消费记录 - 查询客户的基本信息 - 查询学生的活动记录和预算	字段级建议： - 查询具体的月度消费金额 - 查看每个订单的具体金额 - 查看客户的交易货币类型
2	“客户的消费记录”	表级建议： - 查看客户的详细信息 - 查看具体的月度消费数据 - 查看客户的基本信息	字段级建议： - 是否关心每个客户的月度消费总额 - 是否想查看特定时间段内的消费记录 - 是否想查看某个特定货币类型的客户	
3	“查询 yearmonth 表中特定客户的每月消费详情”	字段级建议： - 是否关心特定字段的信息，如客户 ID、月份和消费金额等。 - 是否关注 yearmonth 表中的特定年份的客户消费数据。 - 您可能关心用户的消费水平，比如想找出 2013 年消费最多的客户。		
4	“找出 2013 年消费最多的客户”	生成 SQL： SELECT CustomerID, SUM(Consumption) AS Total_Consumption FROM yearmonth WHERE Date LIKE "2013%%" GROUP BY CustomerID ORDER BY Total_Consumption DESC LIMIT 1;		
Baseline				
1	“查询用户消费情况”	生成 SQL： SELECT account_id, COUNT(loan_id) AS Number_of_Loans FROM loan GROUP BY account_id;		

8 实验验证

8.1 数据集构建

由于早期研究主要聚焦于 SQL 生成的基础能力，模糊需求处理长期被视为“预处理”环节而非核心研究问题，导致现有主流语义解析数据集（如 Spider、Bird[2]）主要面向明确需求设计。所以，为验证系统在模糊场景下的数据导航能力，我们基于 Bird 基准数据集，通过设定多维度模糊化规则构建跨领域评估数据集。具体构建流程如下：

1）基础数据筛选

Bird-fuzzy 从 Bird 的 10 个典型领域数据库（涵盖教育、金融等 6 大领域，如表 5 所列）中随机抽样 200 个查询样本（每个数据库 20 个），确保查询覆盖简单、中等、复杂三种模式。

表 5 Bird-fuzzy 数据集领域分布

Table 5 Domain distribution of the Bird-fuzzy dataset

领域类别	含义	对应数据库
EDU	教育	california_schools, student_club
FIN	金融	debit_card_specializing,financial
MED	医疗	thrombosis_prediction
SPO	体育	european_football_2, formula_1
TECH	技术	codebase_community
ENT	娱乐	card_games,superhero

2）模糊化规则应用

术语层保留领域主体词（如教育领域的“学生”，“机构”，“分数”等），替换专业术语为上位词（如医疗领域“血红蛋白”转换为“血液指标”）；条件层隐藏具体数值/时间（如“＞180mg/dL”→“异常高值”）、模糊化地点约束（如“加利福尼亚州”→“某些地区”），操作层将显示的聚合函数模糊描述为相关信息（如"AVG(age)"→“统计年龄信息”）。对于每个数据库生成的20个模糊需求进行人工筛选，保留模糊度合理、与原始查询意图趋向一致的高质量样本，最终 100 个模糊需求构成数据集，每个模糊需求样本包含以下信息：问题 id，领域标签，数据库名，语义线索，原始查询，模糊查询，真实 SQL。

8.2 评估标准

为量化评估分层元数据驱动的查询需求澄清方法性能，本研究构建了多维度加权评估体系。通过完整记录用户-系统交互会话，从交互效率和质量评估两个维度量化分析性能。

交互效率维度包括标准化处理的对话轮次（Turn，[0-5]分）和时耗（Time，[0-5]分），分别反映系统导航效率和响应速度；质量维度包含用户主观满意度评分（User，[0-5]分）和 LLM 基于动态上下文生成的自评分数（Self-evaluation，[0-10]分），其中用户评分由用户根据交互效果主观给出，而 LLM 自评根据交互上下文是否合理、是否实现渐进式需求精确化、能否生成正确 SQL 及提供解释性证明划分为优秀（8-10 分）、一般（4-7 分）和较差（0-3 分）三档。系统综合评分通过加权求和模型（式 1）计算，其中α，β，γ，λ为权重系数，分别设为 0.1，0.1，0.3，0.5，确保评估结果既包含客观性能指标又兼顾主观质量感知。

$$score = \alpha \cdot Time + \beta \cdot Turn + \gamma \cdot E_{Self-evaluation} + \lambda \cdot E_{User} \quad (1)$$

8.3 实验与分析

8.3.1 模型选择

为系统评估分层元数据架构在数据导航任务中的有效性及泛化能力，本研究设计了多维度的模型对比实验。基于模型规模与专业特性（指令遵循能力和工具调用能力等）的差异化考量，我们选取了以下四个具有代表性的开源大语言模型作为 SQL-MARS 系统的核心推理引擎：LLaMA3.1-8B, Qwen2.5-7B, Qwen2.5-32B, Qwen2.5-Coder-32B。

8.3.2 元数据分层有效性实验及结果分析

为验证分层元数据结构对数据导航任务的系统性影响，我们构建了控制变量实验：以 LLaMA3.1-8B、Qwen2.5-7B、Qwen2.5-32B 和 Qwen2.5-Coder-32B 为测试对象，在保持其他条件（提示词模板、测试数据集、

评估标准）一致的情况下，分别输入分层处理的元数据（按库-表-字段三级组织）与原始混合元数据，对比其综合评分差异。实验数据如表 6 所示：

表 6 分层元数据与原始元数据性能对比

Table 6 Performance comparison between hierarchical metadata and raw metadata

模型	分层元数据评分	原始元数据评分	性能提升幅度(Δ)
LLaMA3.1-8B	72.35	68.44	+3.91 (5.71%)
Qwen2.5-7B	70.19	66.59	+3.60 (5.41%)
Qwen2.5-32B	81.39	74.48	+6.91 (9.28%)
Qwen2.5-Coder-32B	73.84	63.16	+10.68 (16.91%)

如表 6 所示，所有模型在分层元数据条件下均表现更优（平均提升 Δ=6.28 分）。这种提升主要源于分层结构的三方面优势：一是通过层级划分降低了模型处理复杂元数据的认知负荷，二是提供了明确的语义导航路径，三是增强了跨表关联的推理能力。

值得注意的是，代码特化模型（Qwen-Coder-32B）对分层结构的响应最为敏感，这表明专业模型更能从规范化的元数据组织中获益。虽然模型规模对提升幅度有一定影响（32B 模型平均 Δ=8.80 vs 7B/8B 模型平均 Δ=3.76），但分层处理对所有规模模型都显示出正向效果，证实了该方法具有较好的普适性。这些结果为企业级数据系统的元数据管理提供了重要启示：实施分层处理是提升 LLM 数据导航能力的有效手段，尤其在使用专业模型时更为关键。

8.3.3 基于综合性能的模型选择实验

上下文长度（Token 数）限制一直是制约 LLM 效能的一大挑战。为了给 SQL-MARS 选择综合性能较高的模型作为整个系统的核心推理引擎，我们统计了上述四个模型在需求澄清过程中的成本消耗（平均 token 数），综合考量模型性能与计算成本的平衡关系。

表 7 是在元数据分层情况下的各模型性能评估与平均 token 数消耗情况。结果表明，模型表现与计算开销呈现明显的正相关关系。Qwen2.5-32B 虽然取得了最高的平均评分（81.39），但其 Token 消耗达到 13,536.56，是 LLaMA3.1-8B 的 24 倍。由于 Qwen2.5-32B 的平均评分显著领先（较次优模型提升 10.3%），且其平均 token 数在日常应用中是可接受的，所以综合考量下我们选择 Qwen2.5-32B 模型作为 SQL-MARS 的推理模型。

值得注意的是，LLaMA3.1-8B 在保持较高评分（72.35）的同时，Token 消耗仅为 561.69，但其模糊判定能力弱于 Qwen2.5-32B。因此，在用户需求相对明确的场景下，可选用更具性价比的 LLaMA3.1-8B。

表 7 分层元数据下的模型性能与计算成本对比

Table 7 Comparison of model performance and computational cost with hierarchical metadata

模型	平均评分	平均 token 消耗数
LLaMA3.1-8B	72.35	561.69
Qwen2.5-7B	70.19	5697.62
Qwen2.5-32B	81.39	13536.56
Qwen2.5-Coder-32B	73.84	10868.61

8.3.4 实验局限性及改进方向

本次实验所有智能体均采用统一的模型，未能充分考虑不同子任务的特性差异。同时，从不同领域的外部资料中自动、准确地抽取“指标公式”是一项极具挑战性的任务，其准确率高度依赖于优秀指标实体抽取实例、领域内高质量的本体资源、prompt 模板设计以及大模型指令遵循能力，尽管本文提出的外部资料融合机制在实验示例中取得了不错的效果，但是由于缺少包含外部资料的 benchmark，本文并未设计实验统计分析该机制的效果。此外，Bird-fuzzy 数据集规模较小（仅 100 条），且模糊化规则人为设定，可能未覆盖所有真实模糊场景。后续研究可探索异构模型组合策略、扩大数据集规模，并研究提高外部资料指标抽取精度的方法，以提升系统泛化性能。

结束语 本文实现了 SQL-MARS，提出了基于多智能体协同的数据导航框架，该框架专注于面向数据库模糊查询需求的动态判别与自适应处理。我们提出元数据分层的方法构建“库-表-字段”三级语义映射体系，

弥合自然语言与结构化数据之间的语义鸿沟。对于模糊需求，我们设计了基于三层增强元数据检索、优秀示例库检索的多粒度需求建议推荐，以渐进式引导用户明确数据需求。此外，我们探索性地实现了外部非结构化文档与本地结构化元数据的语义对齐，提取有价值的指标以辅助需求建议推荐。这种融合外部语义的推荐方式，为跨域数据探索提供了新的交互范式。在 Bird-fuzzy 数据集上的实验结果表明，SQL-MARS 能够识别模糊需求并有效引导用户澄清。后续将进一步根据不同子任务的特性差异探索异构模型组合策略；对于外部资料中抽取的指标可能与本地数据库数据部分匹配的问题，如何在这类场景下合理地推荐数据分析问题也需要进一步探索。

参 考 文 献

[1] ZHAO X, ZHOU X, LI G. Chat2Data: An Interactive Data Analysis System with RAG, Vector Databases and LLMs[C]// Proceedings of the VLDB Endowment, Vol. 17, No. 12. Association forComputing Machinery, 2024:4481-4484

[2] LI J, HUI B, QU G, et al. Can llm already serve as a database interface? a big bench for large-scale database grounded text-to-sqls[C]// Proceedings of Curran Associates Inc, 2023. https://dl.acm.org/doi/10.5555/3666122.3667957

[3] WU Q, BANSAL G, ZHANG J, et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversations [C]// Proceedings of the First Conference on Language Modeling. 2024.

[4] HONG S, ZHUG M, CHEN J, et al. MetaGPT: Meta Programming for Multi-Agent Collaborative Framework [C]// Proceedings of the 12th International Conference on Learning Representations (ICLR 2024). Vienna, Austria: ICLR, 2024.

[5] XAGENT TEAM. XAgent: An autonomous agent for complex task solving [EB/OL]. XAgent Blog, 2023. [2025-07-14]. https://xagentblog.com/xagent.

[6] WANG B, ZHANG Y, LI X, et al. MAC-SQL: A Multi-Agent Collaborative Framework for Text-to-SQL [C]// Proceedings of the 12th International Conference on Learning Representations (ICLR 2024). Vienna, Austria: ICLR, 2024.

[7] POURREZA M, RAFIEI D, LI B, et al. CHASE-SQL: Multi-Path Reasoning and Preference Optimized Candidate Selection in Text-to-SQL [C]// Proceedings of the 13th International Conference on Learning Representations (ICLR 2025). Vienna, Austria: ICLR, 2025.

[8] YAO S, ZHENG S, YU B, et al. ReAct: Synergizing Reasoning and Acting in Language Models [C]// Proceedings of the 11th International Conference on Learning Representations (ICLR 2023). Vienna, Austria: ICLR, 2023.

[9] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language Agents with Verbal Reinforcement Learning [C]// Advances in Neural Information Processing Systems. 2023, 36: 8634–8652.

[10] TANG N, FAN J, LI F Y, et al. RPT: Relational Pre-trained Trans-former Is Almost All You Need towards Democratizing Data Preparation. [J]// Proc.VLDB Endow, 2021, 14(8):1254–1261

[11] ZHOU X, SUN Z, LI G. DB-GPT: Large Language Model Meets Database [J]. Data Science and Engineering, 2024,9(1):102-111.

[12] ZHAO F H, LIM L, AHMAD I, et al. LLM-SQL-Solver: Can LLMs Determine SQL Equivalence? [J/OL]. (2025-03-12) [2023-12-10]. https://arxiv.org/abs/2312.10321.

[13] ZHOU X, LI G, et al. D-Bot: Database Diagnosis System Using Large Language Models [J/OL]. (2023-12-01) [2023-12-01]. https://arxiv.org/abs/2312.01454.

[14] CHANG S, FOSLER-LUSSIER E. How to Prompt LLMs for Text-to-SQL: A Study in Zero-Shot, Single-Domain, and Cross-Domain Settings[C]//NeurIPS 2023 Second Table Representation Learning Workshop, 2023.

[15] ZHANG B, YE Y, HU X, et al. Benchmarking the Text-to-SQL Capability of Large Language Models: A Comprehensive Evaluation[EB/OL]. 2024. https://arxiv.org/abs/2403.02951.

[16] XIA H, JIANG F, DENG N, et al. SQL-Craft: Text-to-SQL Through Interactive Refinement and Enhanced Reasoning [J/OL]. 2024-02-14. https://arxiv.org/abs/2402.14851v1.

[17] DONG X, ZHANG C, GE Y, et al. C3: Zero-Shot Text-to-SQL with ChatGPT[EB/OL]. 2023 . https://arxiv.org/abs/2307.07306.

[18] POURREZA M, RAFIEI D. DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc.2023:36339-36348.

[19] XIE Y, JIN X, XIE T, et al. Decomposition for Enhancing Attention: Improving LLM-Based Text-to-SQL through Workflow Paradigm[C]//Findings of the Association for Computational Linguistics: ACL 2024. Association for Computational Linguistics, 2024:10796-10816.

[20] DENG M, XU C, HU L, et al. ReFoRCE: A Text-to-SQL Agent with Self-Refinement, Format Restriction, and Column Exploration[C]//ICLR 2025 Workshop: VerifAI: AI Verification in the Wild. International Conference on Learning Representations, 2025.

[21] TAI C, CHEN Z, ZHANG T, et al.Exploring Chain of Thought Style Prompting for Text-to-SQL[C]//Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics,2023:5376-5393.

[22] FRANCISCATTO M, DEL FABRO M, TROIS C, et al. Talk to Your Data: A Chatbot System for Multidimensional Datasets[C]//2022 IEEE 46th Annual Computers, Software, and Applications Conference. IEEE Computer Society,2022:486-495.

[23] CHAUDHURI R, et al. Automated Question Generation on Tabular Data for Conversational Data Exploration[EB/OL]. 2025. https://arxiv.org/abs/2407.12859.

[24] MANATKAR A, AKELLA A, GUPTA P, et al. QUIS: Question-Guided Insights Generation for Automated Exploratory Data Analysis[C]//2024 Conference on Empirical Methods in Natural Language Processing: Industry Track. Association for Computational Linguistics, 2024:1523-1535.

徐嘉雯，出生于 2001 年，华东师范大学，硕士研究生，主要研究方向为大模型支持的智能化数据库管理。

郑云贵，出生于 2000 年，华东师范大学，硕士研究生，主要研究方向为 RAG，大模型推理优化。

周伟，出生于 2000 年，华东师范大学，硕士研究生，主要研究方向为数据管理系统。

徐尧强，国家电网有限公司华东分部，主要研究方向为数据管理系统，智能化数据管理。

胡卉芪，出生于 1988 年，华东师范大学，教授，博士生导师，主要研究方向为新型数据管理系统，智能系统。

周烜，出生于 1978 年，华东师范大学，教授，博士生导师，主要研究方向为数据库系统和信息检索技术。

XU Jiawen，born in 2001, postgraduate. Her main research interests include LLM-powered intelligent database management.

HU Huiqi ， born in 1988, Ph.D, professor, Ph.D supervisor. His main research interests include next-generation data management systems and intelligent systems.