基于轻量算力资源的Text2SQL方法设计与实现

胡永波，袁龙，周磊
（云赛智联股份有限公司，上海数翊信息技术分公司，上海 200233）

摘要：阐述一种结合轻量化模型、量化技术、微调策略、提示词工程和GraphRAG图谱的方案。通过对小模型进行量化和微调，并对数据进行精细的标注和处理，在保留关键性能的同时大幅度降低了硬件算力要求。

关键词：轻量化模型，Text2SQL，模型量化，LoRA微调，提示词工程，GraphRAG，数据标注。

中图分类号：TP18，TP391.1
文章编号：1000-0755(2025)05-0126-02
文献引用格式：胡永波，袁龙，周磊.基于轻量算力资源的Text2SQL方法设计与实现[J].电子技术, 2025, 54(05): 126-127.

Design and Implementation of Text2SQL Method Based on Lightweight Computing Resources

HU Yongbo, YUAN Long, ZHOU Lei
(Yunsai Zhilian Co., Ltd. Shanghai Shuyi Information Technology Branch, Shanghai 200233,China.)

Abstract — This paper expounds a solution that combines lightweight models, quantization techniques, fine-tuning strategies, prompt word engineering, and GraphRAG graphs. It quantifies and fine tunes small models, and finely annotates and processes data, significantly reducing hardware computing power requirements while retaining key performance.

Index Terms — lightweight model, Text2SQL, model quantification, LoRA fine-tuning, prompt word engineering, GraphRAG, data annotation.

0 引言

随着自然语言处理领域的大规模预训练模型的崛起，像GPT和T5等大模型在Text2SQL任务中展示了出色的性能。随着模型规模的增加，硬件算力资源需求也成倍增长，导致中小型企业难以在有限的算力条件下高效部署这些模型。本文提出一种通过小模型量化的方式，结合LoRA微调技术，并加强数据处理和标注工作，同时引入提示词工程和GraphRAG图谱，优化模型在Text2SQL任务中的生成能力，从而减少部署成本，实现资源受限环境下的高效SQL生成。

1 研究背景

本实验在Text2SQL场景下，通过两条路径对自然语言进行相关处理。第一部分首先选择一个小模型并对其量化处理；其次通过数据预处理与标注对原始SQL语句进行处理生成数据集，然后结合模型量化后的结果进行LoRA微调生成垂类小模型。第二部分以DDL脚本为基础构建图库、建立索引生成GraphRAG知识图谱。当通过自然语言进行提问后，会通过提示词工程访问第一部分的垂类小模型生成SQL语句，且同时通过图引导检索和图增强生成访问第二部分的GraphRAG知识图谱生成SQL语句，将两条SQL语句再通过LLM整理得出最后的输出结果。如图1所示。

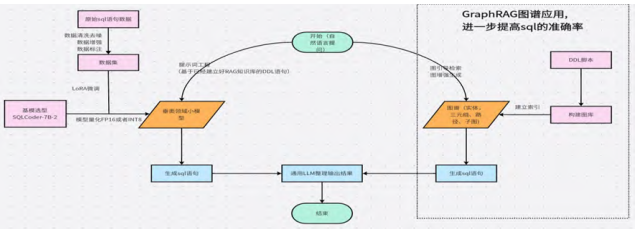

图1 实验方法设计

2 研究方法设计

2.1 模型选择与量化

在Text2SQL场景下，选择较小的模型作为基模时，需要兼顾准确性、推理速度和资源效率，因此选用SQLCoder-7B-2模型。量化技术的应用能够在保持模型性能的前提下大幅降低硬件要求，使得轻量化模型成为可能[1]。为了确保在低精度下的模型性能，我们采用了动态量化与静态量化相结合的校准方式，从而显著减少内存占用和计算复杂度。

2.2 数据预处理与标注

针对Text2SQL任务，训练数据的准确性和质量直接影响SQL生成的精确度，因此需要对原始数据进行预处理：（1）通过自动和手动的方式去除不准确的标签、冗余的SQL查询或语义歧义等。（2）对现有数据集的标注进行了重新审查和标注，确保每一个SQL元素都有明确的语义指代。（3）在保持查询语义不变的前提下，通过修改句法结构、改变

作者简介：胡永波，云赛智联股份有限公司，上海数翊信息技术分公司；研究方向：智能控制技术。
收稿日期：2025-02-10；修回日期：2025-05-11。

中国知网 https://www.cnki.net

语序等方式生成多种不同形式的自然语言查询，以提升模型在不同表述上的泛化能力。

2.3 LoRA微调

当模型量化和数据处理完成后，使用LoRA技术微调。LoRA通过在模型的低秩矩阵上进行微调，减少了需要更新的参数量，使模型在保持预训练知识的基础上快速适应特定任务，并降低硬件要求。

2.4 提示词工程设计

提示词工程（Prompt Engineering）是提高轻量化模型性能的重要手段之一，合理的提示词设计可以有效引导模型生成正确的SQL查询。为了增强轻量化模型的性能，本研究基于已建立的RAG知识库的DDL语句，开发显式提示词模板，引导模型生成准确的SQL查询，并根据查询复杂度动态调整提示词。

2.5 GraphRAG图谱应用

与传统的RAG不同，GraphRAG图谱从预先构建的图数据库中检索与给定查询相关且包含关系知识的图元素，这些元素可能包括节点、三元组、路径或子图。GraphRAG考虑了文本之间的联系，能够更准确、更全面地检索关系信息。通过将知识图谱中的节点与模型生成过程结合，GraphRAG能为模型提供更加丰富的上下文支持，尤其适用于复杂的SQL生成任务。

在Text2SQL任务中，将数据库的表结构、字段、外键关系等信息构建成图谱，模型在生成SQL时可以检索这些关系，从而生成更加精确的SQL查询，尤其是复杂的多表联结查询。另外，GraphRAG通过检索知识图谱中的相关节点，为模型生成过程提供额外的背景信息。例如，当模型需要生成一个涉及多个表的联结查询时，图谱中的关系信息 可以帮助模型更好地理解字段之间的映射关系。这种方法不仅增强了轻量化模型在复杂SQL生成中的表现，还显著降低了模型对计算资源的需求。

3 实验案例

3.1 实验过程

（1）第一步，对原始的SQL语句进行意图标注和字段与表标注，生成的标注内容如图2所示。（2）第二步，使用已经标注好的数据集对模型进行Lora微调。在训练循环中，对每个批次的数据进行处理：首先清零梯度，进行前向传播计算输出和损失，随后执行反向传播以计算梯度。之后，通过梯度裁剪来防止梯度爆炸，最后更新模型参数。（3）第三步，进行提示词设计。部分设计模板展示如图3所示。

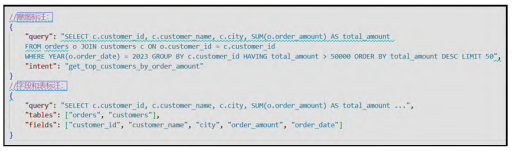

图2 实验过程1（标注内容）

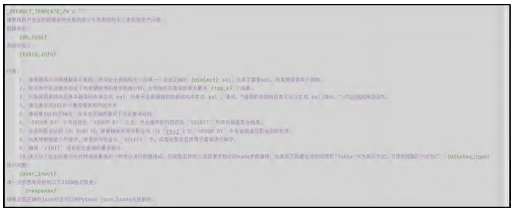

图3 实验过程2（模板展示）

3.2 实验结果

本次实验借助开源的AI原生数据应用开发框架DB-GPT进行效果展示，处理后的模型放在/DB-GPT/models路径下。最终运行效果如图4所示。

图4 运行效果

3.3 实验评估

（1）准确率：在Spider和WikiSQL等数据集上，量化模型结合提示词和GraphRAG后，性能与未量化的大模型接近，准确率损失控制在5%以内。（2）推理速度：采用INT8量化后，推理速度提升了3倍。然而在FP16模式下，虽然精度更高，但推理速度仍稍低于INT8。INT8量化在计算效率和内存带宽方面具有更大的优势，因此在推理时通常会比FP16更快。（3）资源消耗：使用LoRA的方式进行微调，微调过程所需显存减少约50%。量化到INT8极大地减少了推理过程中的内存占用、带宽压力和计算负担，显著降低了硬件资源需求，适合资源受限的部署场景。如表1所示。

4 结语

本研究提出的轻量化模型结合量化技术、LoRA微调、提示词工程以及GraphRAG图谱在Text2SQL任务中的应用，成功降低了硬件资源消耗，保持了较高的任务准确率。通过数据标注与处理工作，模型在轻量化的条件下展现出与大模型相当的效果。这一方法为中小型企业在有限资源下部署AI系统提供了可行方案，为未来的轻量化AI研究指明了方向。

参考文献

[1] 刘昆麟，屈新纪，谭芳，等. 大语言模型对齐研究综述[J]. 电信科学，2024，40(06)：173-194.

表1 实验评估

模型	需求1	识别正确率		需求2	识别正确率		推理所需显存	
		前	后		前	后	前	后
SQLCoder-7b-2(经过调优方法前后对比)	查询每个部门的平均工资，并且只显示平均工资超过10 000元的部门，按平均工资从高到低排序	0.85	0.91	查询订单表中，每个客户在2023年下单的总金额，且只显示总金额大于50 000元的客户，按总金额从大到小排序	0.79	0.88	28GB	14GB

中国知网 https://www.cnki.net